



Evaluación del rendimiento de los biomarcadores en regiones de alta sensibilidad

Paquete Bioconductor · Área Parcial ROC · MCpAUC · TpAUC · NpAUC · FpAUC
Bootstrap · Alta especificidad · Alta sensibilidad · Curvas ROC impropias · Biomarcadores genómicos

Tipo de trabajo

Trabajo Fin de Máster


Departamento

Estadística e I.O.


Curso académico

2025 / 2026

FPR domain — Alta especificidad



TPR domain — Alta sensibilidad



MCpAUC

Alta especificidad
Solo curva propia

TpAUC

Alta especificidad
Curva impropia OK

NpAUC

Alta sensibilidad
RVN acotada

FpAUC

Alta sensibilidad
Curva impropia OK

MCpAUC

TpAUC

NpAUC

FpAUC

Bootstrap

Bioconductor

R package

4

Índices pAUC escalados

11

Funciones exportadas

3

Datasets genómicos reales

10.000

Réplicas bootstrap

Agustín Chumillas Roldán

Tutora: Juana-María Vivo Molina

Tutor: Manuel Franco Nicolás

Murcia, 2025 / 2026

Índice

Resumen	2
Abstract.....	2
1. Introducción	3
2. Justificación y Objetivos	5
3. Materiales y Métodos	6
3.1 Curva ROC	6
3.1.1 Cálculo de la curva ROC	6
3.1.2 Área parcial de la curva ROC.....	6
3.1.3 Índices del área parcial.....	7
3.2 Librerías.....	7
3.2.1 Paquete ROCpAI	7
3.2.2 Dependencias.....	10
3.2.3 Conjuntos de datos.....	11
3.3 Validación de la implementación.....	11
3.4 Análisis de las nuevas bases de datos	12
4. Resultados.....	13
4.3 Validación de la implementación.....	13
4.4 Análisis de las bases de datos	14
4.4.1 Metástasis en cáncer de mama (breastCancerVDX).....	14
5. Discusión	17
5.1 Funcionalidad implementada sobre ROCpAI.....	17
5.2 Validación con los datasets de Franco & Vivo (2021).....	17
5.3 Aplicación a datos de expresión génica de alta dimensionalidad: breastCancerVDX.....	17
5.3 Limitaciones.....	18
5.4 Trabajo futuro	19
6. Conclusiones	19
Referencias	20
Apéndice. Objetivos de Desarrollo Sostenible	23

Resumen

La evaluación rigurosa de biomarcadores diagnósticos en datos ómicos exige herramientas estadísticas adaptadas a las restricciones clínicas de especificidad o sensibilidad. El área parcial bajo la curva ROC (pAUC) es la medida de referencia en estos escenarios, pero sus versiones estandarizadas presentan limitaciones importantes frente a curvas ROC impropias, frecuentes en datos de expresión génica, y no siempre permiten discriminar biomarcadores con igual pAUC.

En este trabajo se presenta una funcionalidad implementable en un paquete de Bioconductor como ROCpAI (García et al., 2026), no disponible en la versión actual del paquete. Concretamente, la funcionalidad de los índices escalados de área parcial NpAUC (Jiang et al., 1996) y FpAUC (Franco & Vivo, 2021) para el dominio de alta sensibilidad (TPR), con soporte nativo a estructuras de datos complejas como *data.frame* y *SummarizedExperiment*, junto con sus correspondientes versiones intervalos de confianza bootstrap al nivel de confianza del 95 %. Asimismo, se introduce una versión modificada de la función *pointsCurve* para la generación de curvas ROC siguiendo la lógica del paquete ROCR (Sing et al., 2005), que mejora las representaciones gráficas con sombreado de la región de área parcial.

La utilidad biológica de la nueva funcionalidad se demostró mediante el análisis de la cohorte de cáncer de mama breastCancerVDX (Minn et al., 2007; Wang et al., 2005), disponible en Bioconductor, identificando cinco genes candidatos a biomarcadores de metástasis a distancia (EEF1A2, NOL3, ZBTB10, DDX24 y GAS2). Todas las curvas ROC de los genes seleccionados clasificaron como impropias en la banda de alta sensibilidad, lo que impidió el cálculo de NpAUC e ilustró la necesidad de FpAUC como único índice aplicable en este contexto. ZBTB10 destacó como el mejor biomarcador del panel (FpAUC = 0.770, IC 95 %: [0.641, 0.856]).

Palabras clave: curva ROC, área parcial, biomarcadores, Bioconductor, bootstrap, expresión génica, curvas impropias.

Abstract

The rigorous evaluation of diagnostic biomarkers in omic data requires statistical tools adapted to clinical constraints on specificity or sensitivity. The partial area under the ROC curve (pAUC) is the standard measure in these scenarios, but its standardised versions present important limitations when facing improper ROC curves —frequent in gene expression data— and do not always allow discrimination between biomarkers with equal pAUC.

This work presents a functionality that can be implemented in a Bioconductor package such as ROCpAI (García et al., 2026), which is not available in the current version of the package. Specifically, the capacities of the scaled partial area indices NpAUC (Jiang et al., 1996) and FpAUC (Franco and Vivo, 2021) for the high-sensitivity domain (TPR), with native support for complex data structures such as *data.frame* and *SummarizedExperiment*, along with their corresponding 95% bootstrap confidence interval versions. Furthermore, a modified version of the *pointsCurve* function is introduced for generating ROC curves following the logic of the ROCR package (Sing et al., 2005), which improves graphical representations by shading the partial area region.

The biological utility of the new functionality was demonstrated through the analysis of the breast cancer cohort breastCancerVDX (Minn et al., 2007; Wang et al., 2005), available in Bioconductor, identifying five candidate biomarkers for distant metastasis (EEF1A2, NOL3, ZBTB10, DDX24 and GAS2). All ROC curves from the selected genes were classified as improper in the high-sensitivity band, preventing the calculation of NpAUC and illustrating the need for FpAUC as the only applicable index in this context. ZBTB10 stood out as the best biomarker of the panel (FpAUC = 0.770, 95% CI: [0.641, 0.856]). In particular, FpAUC outperforms NpAUC in two critical aspects: it guarantees coherent values in [0.5, 1] even for improper curves, and it allows discrimination between biomarkers that produce an exact tie with the Jiang et al. index (1996).

Keywords: ROC curve, partial area, biomarkers, Bioconductor, bootstrap, gene expression, improper curves.

1. Introducción

Los avances en tecnologías de alto rendimiento han transformado la investigación biomédica y la práctica clínica durante las últimas décadas. Las plataformas de microarrays y, más recientemente, la secuenciación masiva de ARN, permiten cuantificar simultáneamente la expresión de miles de genes en un mismo experimento. Esto genera conjuntos de datos de altísima dimensionalidad cuyo análisis requiere metodología estadística específica (Dudoit et al., 2002; Golub et al., 1999). En este contexto, un biomarcador dicotómico es cualquier característica medible, como el nivel de expresión de un gen, que permite distinguir entre dos estados biológicos o clínicos de interés; por ejemplo, tejido tumoral frente a tejido sano, o dos subtipos de leucemia. La capacidad discriminatoria de un biomarcador cuantitativo se evalúa habitualmente mediante herramientas estadísticas que relacionan la sensibilidad y la especificidad del clasificador a lo largo de todos los posibles umbrales de decisión (Fawcett, 2006; Pepe, 2003).

La clasificación molecular de tumores a partir de datos de expresión génica es uno de los campos que más se ha beneficiado de estos desarrollos. El trabajo seminal de Golub et al. (1999) demostró que los perfiles de expresión de microarrays permiten distinguir entre leucemia linfocítica aguda (ALL) y leucemia mieloide aguda (AML) con elevada precisión. Estudios posteriores (Dudoit et al., 2002) realizaron comparaciones sistemáticas de métodos de discriminación aplicados a estos mismos conjuntos de datos. Estas investigaciones establecieron la expresión génica de alta dimensión como una fuente de biomarcadores para diagnóstico y clasificación, y motivaron el desarrollo de métricas de evaluación adaptadas a las particularidades de estos datos.

La curva ROC (Receiver Operating Characteristic) es la representación estándar del rendimiento de un clasificador binario. Para cada umbral de decisión se calcula la tasa de verdaderos positivos (TPR), que equivale a la sensibilidad, y la tasa de falsos positivos (FPR, $1 - \text{especificidad}$). La curva traza todos los pares de tasa de falsos positivos (FPR) y tasa de verdaderos positivos posibles (TPR) al variar el umbral continuamente. Una curva que coincide con la diagonal principal representa un clasificador sin capacidad discriminatoria, mientras que el punto (0, 1) corresponde al clasificador perfecto (Fawcett, 2006; Metz, 1978). El área bajo la curva ROC, conocida habitualmente como AUC, resume el rendimiento global del biomarcador en un único escalar entre 0 y 1. Se interpreta como la probabilidad de que, tomados al azar un individuo positivo y uno negativo, el biomarcador asigne una puntuación más alta al positivo. Un AUC igual a 0.5 equivale a una clasificación aleatoria, mientras que un AUC igual a 1 indica una discriminación perfecta (Pepe, 2003).

Sin embargo, el AUC global puede resultar una medida inadecuada cuando la aplicación clínica impone restricciones sobre alguno de los dos ejes. En diagnóstico rutinario, por ejemplo, suele ser prioritario mantener la especificidad por encima de un umbral mínimo, es decir, una tasa de falsos positivos baja, de modo que un buen biomarcador debe demostrar alta sensibilidad precisamente en esa región. Un AUC global alto no garantiza un rendimiento satisfactorio en la región de interés si el biomarcador concentra su capacidad discriminatoria en una zona clínicamente irrelevante (Dodd & Pepe, 2003; Thompson & Zucchini, 1989).

De igual manera, en programas de cribado poblacional y oncología clínica, como la detección precoz de cáncer de ovario (Pepe et al., 2001), el diagnóstico neonatal de enfermedades raras (Sing et al., 2005) o la identificación de pacientes con cáncer de mama en riesgo de metástasis a distancia (van 't Veer et al., 2002; Wang et al., 2005), el requisito prioritario es la sensibilidad. Se exige que el test identifique prácticamente todos los casos positivos (TPR alto), incluso a costa de incrementar el número de falsos positivos. En estos contextos, un AUC global elevado puede ocultar un rendimiento deficiente precisamente en la región de alta sensibilidad, donde el diagnóstico tiene mayor impacto clínico (Dodd & Pepe, 2003; Thompson & Zucchini, 1989). Esta dualidad, caracterizada por la restricción de especificidad o la restricción de sensibilidad, es la motivación central del presente trabajo y justifica la necesidad de índices de área parcial adaptados a cada dominio (Dodd & Pepe, 2003; McClish, 1989).

Para superar esta limitación, se propuso el índice de área parcial bajo la curva ROC, denominada pAUC (McClish, 1989). Esta se define como la integral de la tasa de verdaderos positivos (TPR) sobre un subintervalo restringido del eje de la tasa de falsos positivos (FPR). Si t_1 y t_2 son los límites inferior y superior del intervalo de interés, el pAUC viene definido por la Ecuación (1).

$$pAUC(t_1, t_2) = \int_{t_2}^{t_1} TPR(t) dt \quad (1)$$

Esta integral se estima en la práctica mediante la regla del trapecio sobre los puntos de la curva ROC empírica en el subintervalo $[t_1, t_2]$, interpolando los puntos de frontera cuando los límites del intervalo no coinciden exactamente con puntos de la curva. El pAUC toma valores en $[0, \Delta t]$, lo que dificulta la comparación directa entre subintervalos de distinto tamaño (Dodd & Pepe, 2003). Para paliar este problema se introdujo la estandarización del pAUC. McClish (1989) propuso el índice McpAUC, que reescala el pAUC al intervalo entre $[0.5, 1]$. De forma análoga, para el dominio de alta sensibilidad, Jiang et al. (1996) definieron el índice NpAUC, que normaliza el pAUC horizontal, el cual se integra respecto al eje de la tasa de verdaderos positivos (TPR), dividiéndolo por la amplitud de la banda de sensibilidad seleccionada.

Una curva ROC se denomina propia cuando permanece estrictamente por encima de la diagonal en todo su recorrido, lo que implica que la razón de verosimilitud positiva (RVP) es no decreciente a lo largo del eje de la tasa de falsos positivos (FPR) (Fawcett, 2006; Pepe, 2003). En datos procedentes de experimentos de expresión génica, no obstante, es frecuente observar curvas impropias que cruzan la diagonal en algún punto o incluso que se sitúan por debajo de ella en una región determinada (Cleves, 2002; Hanley, 1988). La presencia de curvas impropias invalida directamente el índice de McClish (McpAUC), ya que su fórmula de estandarización asume que la curva se encuentra por encima de la diagonal (McClish, 1989; Vivo et al., 2018). Asimismo, el índice NpAUC de Jiang et al. (1996) puede producir valores menores que 0.5, interpretables erróneamente como rendimiento inferior al azar (Franco & Vivo, 2021). Bandos et al. (2017) mostraron que el ajuste binormal estándar puede generar curvas de forma impropia incluso cuando los datos proceden de una curva propia. En el contexto del análisis no paramétrico con datos ómicos, la irregularidad de la curva empírica es la norma más que la excepción (Krzanowski & Hand, 2009), lo que hace imprescindible contar con índices que mantengan sus propiedades de interpretación independientemente de la forma de la curva (Franco & Vivo, 2021).

Para resolver estas limitaciones, se han propuesto en la literatura otro tipo de índices escalados que garantizan valores en $[0.5, 1]$ bajo condiciones apropiadas, cubriendo los dominios de alta especificidad (FPR bajo) y alta sensibilidad (TPR alto). La **¡Error! No se encuentra el origen de la referencia.** resume sus características principales.

Tabla 1. Índices escalados de área parcial bajo la curva ROC.

Índice	Dominio	Condición de validez	Referencia
McpAUC	Alta especificidad (FPR)	Curva ROC propia (por encima de la diagonal)	McClish (1989)
TpAUC	Alta especificidad (FPR)	Cualquier forma de curva ROC	Vivo et al. (2018)
NpAUC	Alta sensibilidad (TPR)	RVN acotada por su valor en TPR_0	Jiang et al. (1996)
FpAUC	Alta sensibilidad (TPR)	Cualquier forma de curva ROC	Franco y Vivo (2021)

2. Justificación y Objetivos

El índice MCpAUC de McClish (1989) se convirtió rápidamente en la referencia estándar para la evaluación de biomarcadores en regiones de alta especificidad. Sin embargo, su definición matemática requiere que la curva ROC se sitúe, en todo momento, por encima de la diagonal principal. Cuando esta condición no se cumple, lo que es un escenario habitual en datos de expresión génica de alta dimensión, el índice queda indefinido. Para solventar esta limitación, Vivo et al. (2018) demostraron que las cotas utilizadas por MCpAUC son las más amplias posibles y, por tanto, subóptimas para curvas que no son impropias. En su lugar, propusieron cotas más ajustadas basadas en la clasificación de la forma de la curva mediante la razón de verdaderos positivos (RVP) parcial, dando lugar al índice TpAUC, el cual extiende el uso de MCpAUC al conjunto completo de curvas ROC empíricas.

Por otro lado, en numerosas aplicaciones clínicas y de cribado poblacional, el requisito prioritario no es la especificidad, sino la sensibilidad; es decir, se exige que el test detecte la práctica totalidad de los casos positivos (RVP alta), asumiendo una mayor tasa de falsos positivos. En este dominio, el índice NpAUC de Jiang et al. (1996) constituye la contrapartida de MCpAUC para el eje de la sensibilidad. No obstante, NpAUC hereda la misma restricción estructural: solo es válido cuando la razón de falsos positivos (RFP) está acotada por su valor de referencia. Para cubrir esta laguna, Franco y Vivo (2021) desarrollaron el índice FpAUC. El algoritmo propuesto en dicho artículo clasifica la curva según el comportamiento de la RFP en la región de alta sensibilidad y selecciona las cotas más estrechas aplicables a cada caso. Esto garantiza que el índice FpAUC sea matemáticamente consistente, con independencia de la forma de la curva, y que sus valores se sitúen siempre en el intervalo [0.5, 1].

El objetivo principal de este Trabajo Fin de Máster es presentar una funcionalidad implementable en un paquete de Bioconductor como ROCpAI (Garcia et al., 2026) no disponible en la versión actual del paquete. De manera específica, se plantean los siguientes objetivos:

Objetivo 1: Desarrollar la funcionalidad de los diferentes índices escalados de área parcial ROC para la evaluación de rendimiento de biomarcadores en regiones de alta sensibilidad, no disponibles en la versión actual del paquete ROCpAI de Bioconductor.

- 1.1. Implementar los índices NpAUC y FpAUC para la zona de alta sensibilidad, junto con la modificación de la función `pointsCurve` para la generación de curvas ROC siguiendo la lógica del paquete `ROCR` (Sing et al., 2005), ofreciendo soporte nativo para estructuras de datos complejas como `data.frame` y `SummarizedExperiment`.
- 1.2. Realizar mejoras visuales en las gráficas, optimizar las salidas del paquete, completar la documentación mediante `Roxygen2` y asegurar la robustez del código a través de la verificación formal con `R CMD check`.

Objetivo 2: Aplicar y validar la utilidad de la herramienta mediante el análisis de datos genómicos reales.

- 2.1. Aplicar la nueva funcionalidad a tres conjuntos de datos clínicos independientes disponibles en Bioconductor — `breastCancerVDX`, metástasis a distancia en cáncer de mama (Minn et al., 2007; Wang et al., 2005), `GSE13015`, sepsis bacteriana (Pankla et al., 2009) y `GSE83456`, tuberculosis pulmonar activa frente a otras enfermedades respiratorias, (Singhania et al., 2018)— evaluando el rendimiento de los índices NpAUC y FpAUC en el dominio de alta sensibilidad e interpretando los resultados en su contexto clínico.
- 2.2. Utilizar las bases de datos de Leucemia ALL/AML (`golubEsets`), Cáncer de Colon (`plsgenomics`) y Cáncer de Ovario (`orchratio2`), empleadas por Franco y Vivo (2021), como punto de control para verificar la correcta implementación de los índices y comparar los resultados con los publicados.

3. Materiales y Métodos

En este apartado se describen los fundamentos teóricos del análisis de curvas ROC y los índices de área parcial necesarios para el desarrollo de la nueva funcionalidad, cuya implementación se detalla a continuación. Posteriormente se presentan las librerías utilizadas, incluyendo las funciones implementables en el paquete ROCpAI, las dependencias externas y los conjuntos de datos empleados tanto para la aplicación principal como para la validación de los resultados.

3.1 Curva ROC

3.1.1 Cálculo de la curva ROC

La curva ROC es una curva que se obtiene al representar en un gráfico bidimensional, en el eje Y la sensibilidad o Tasa de Verdaderos Positivos (TPR), y en el eje X la Tasa de Falsos Positivos (FPR, 1 – especificidad).

La sensibilidad y la especificidad se calculan a partir de los valores que el clasificador ha asignado a cada muestra. Los casos cuyo valor quede por encima de un umbral determinado se tomarán como positivos, mientras que los que queden por debajo serán negativos. Esto clasifica las muestras para cada umbral de la siguiente forma:

- **Verdaderos Positivos (TP):** caso positivo clasificado correctamente como positivo.
- **Verdaderos Negativos (TN):** caso negativo clasificado correctamente como negativo.
- **Falsos Positivos (FP):** caso negativo clasificado erróneamente como positivo.
- **Falsos Negativos (FN):** caso positivo clasificado erróneamente como negativo.

A partir de estos cuatro recuentos se calculan la tasa de verdaderos positivos $TP/(TP + FN)$ (2) y la tasa de falsos positivos $FP/(FP + TN)$ (3) para cada umbral (Fawcett, 2006; Pepe, 2003).

$$TPR = TP/(TP + FN) \quad (2)$$

$$FPR = FP/(FP + TN) \quad (3)$$

Al representar estos dos valores para todos los umbrales posibles se obtiene la curva ROC. Se espera que ésta quede por encima de la diagonal que une los puntos (0, 0) y (1, 1), ya que dicha diagonal corresponde a un clasificador aleatorio. Cuanto más se aproxime la curva al punto (0, 1), mayor es la capacidad discriminatoria del biomarcador (Fawcett, 2006; Metz, 1978).

Sin embargo, esto no siempre ocurre. Cuando al aumentar el umbral de decisión la tasa de falsos positivos crece más rápido que la tasa de verdaderos positivos, la curva avanza en horizontal y puede cruzar la diagonal, produciéndose lo que se denomina una curva impropia. En términos formales, esto ocurre cuando la razón de verosimilitud positiva (RVP = TPR/FPR) no es monótona no decreciente en algún punto del recorrido, es decir, cuando el biomarcador discrimina peor que el azar en alguna región o tramo de umbrales (Pepe, 2003; Vivo et al., 2018).

3.1.2 Área parcial de la curva ROC

En numerosas aplicaciones clínicas no es relevante el rendimiento global del biomarcador sino su comportamiento en una región restringida de la curva ROC. El área bajo la curva ROC completa, AUC, puede resultar una medida inapropiada cuando la aplicación impone restricciones sobre alguno de los dos ejes, ya que un AUC global alto no garantiza un rendimiento satisfactorio en la región de interés clínico (Dodd & Pepe, 2003).

Para superar esta limitación, McClish (1989) propuso el área parcial bajo la curva ROC, denominada pAUC, definida como la integral de la TPR sobre un subintervalo restringido del eje FPR. Si FPR_0 y FPR_1 son los límites inferior y superior del intervalo de interés, el pAUC en el dominio de alta especificidad viene dado por la Ecuación (4).

$$pAUC(FPR_0, FPR_1) = \int_{FPR_0}^{FPR_1} TPR(FPR^{-1}(t)) dt \quad (4)$$

De forma análoga, cuando el requisito clínico prioritario es la sensibilidad, Jiang et al. (1996) definieron el pAUC sobre un subintervalo restringido del eje TPR, integrando la especificidad respecto al eje de verdaderos positivos en el intervalo $[TPR_0, 1]$ (5).

$$pAUC(TPR_0, 1) = \int_{TPR_0}^{FPR_1} (1 - FPR \circ TPR^{-1}(s)) ds \quad (5)$$

En ambos casos, el pAUC se estima mediante la regla del trapecio compuesto sobre los puntos de la curva ROC empírica en el subintervalo de interés, interpolando los puntos de frontera cuando los límites no coinciden exactamente con puntos de la curva (Dodd & Pepe, 2003; McClish, 1989).

El pAUC toma valores en $[0, \Delta]$, donde Δ es la amplitud del subintervalo considerado, lo que dificulta la comparación directa entre subintervalos de distinto tamaño o entre estudios distintos. Para paliar este problema se introdujo la estandarización del pAUC mediante índices escalados, que transforman el área a un intervalo común e interpretable (Jiang et al., 1996; McClish, 1989).

3.1.3 Índices del área parcial

El cálculo del pAUC tiene interés para comparar la eficacia entre biomarcadores en una determinada región de la curva ROC. No obstante, como se ha mencionado anteriormente, el pAUC depende del tamaño del subintervalo considerado, por lo que es necesario estandarizarlo para poder realizar comparaciones válidas. Los índices escalados transforman el pAUC a un intervalo interpretable $[0.5, 1]$, donde 0.5 corresponde al clasificador aleatorio y 1 al clasificador perfecto.

En el dominio de alta especificidad, el paquete ROCpAI (Garcia et al., 2026) dispone de los índices MCpAUC (McClish, 1989), que opera sobre curvas propias, y TpAUC (Vivo et al., 2018), que extiende MCpAUC a cualquier forma de curva ROC mediante cotas más ajustadas basadas en la clasificación de la curva por la razón de verosimilitud positiva (RVP) parcial. Este trabajo desarrolla la implementación de los dos índices equivalentes para el dominio de alta sensibilidad: NpAUC y FpAUC.

El índice NpAUC, propuesto por Jiang et al. (1996), constituye la contrapartida de MCpAUC para el dominio de alta sensibilidad $TPR \in [TPR_0, 1]$. Su cálculo normaliza el pAUC horizontal, es decir, el área integrada respecto al eje TPR, dividiéndolo por el ancho de la banda de sensibilidad seleccionada. Sin embargo, este índice hereda la misma restricción estructural que MCpAUC: solo es válido cuando la razón de verosimilitud negativa (RVN) permanece acotada por su valor de referencia RVN_0 en toda la banda $[TPR_0, 1]$. Cuando esta condición no se cumple, lo que ocurre con frecuencia en datos de expresión génica de alta dimensionalidad, este índice puede producir valores en $(0, 0.5)$, interpretables erróneamente como rendimiento inferior al azar (Franco & Vivo, 2021).

Para cubrir esta laguna, Franco y Vivo (2021) desarrollaron el índice FpAUC, que extiende NpAUC aplicando cotas óptimas que dependen de la clasificación de la curva mediante la RVN parcial. El algoritmo propuesto en dicho artículo distingue tres casos mutuamente excluyentes según el comportamiento de la RVN en la región de alta sensibilidad: acotada por RVN (*BpNLR*), parcialmente propia (*pProp*), o curva impropia (*other*), seleccionando en cada caso las cotas más estrechas aplicables. Esto garantiza que $FpAUC \in [0.5, 1]$ independientemente de la forma de la curva ROC, resolviendo las dos limitaciones conocidas de NpAUC: la indeterminación ante curvas impropias y la incapacidad de discriminar biomarcadores con igual pAUC.

3.2 Librerías

3.2.1 Paquete ROCpAI

Las funciones desarrolladas como nueva funcionalidad para el paquete ROCpAI (Garcia et al., 2026) se pueden encontrar en el siguiente repositorio: <https://github.com/achumillas/ROCpAUC>.

pointsCurve: Esta función ha sido modificada respecto a su implementación en el paquete ROCpAI (Garcia et al., 2026) para construir la curva ROC empírica siguiendo la misma lógica que el paquete ROCR (Sing et al., 2005). La función acepta dos parámetros de entrada: un vector de etiquetas binarias y un vector de puntuaciones del predictor. El algoritmo determina todos los umbrales únicos ordenados descendientemente; para cada umbral calcula los recuentos acumulados de verdaderos positivos y falsos positivos mediante cumsum; obtiene las tasas $TPR = TP/n_pos$ y $FPR = FP/n_neg$; y por último

elimina los pares (FPR, TPR) duplicados y los ordena por FPR ascendente. La función devuelve un `data.frame` con las columnas FPR y TPR correspondientes a la curva ROC empírica. Opcionalmente, mediante el argumento `plot = TRUE`, genera un gráfico individual de la curva ROC mediante `ggplot2` (Wickham, 2016), con la diagonal de referencia y el título configurable mediante el argumento `label`.

pAUC: Esta función calcula el área parcial bajo la curva ROC en el subintervalo de interés, sin aplicar ningún escalado (Dodd & Pepe, 2003; McClish, 1989). La función acepta los siguientes parámetros:

- **dataset:** contiene la información a partir de la cual se generará la curva ROC. Puede ser un objeto de tipo `data.frame` o `SummarizedExperiment`. En caso de ser un `data.frame`, la primera columna debe ser el Gold Standard binario y las siguientes columnas los predictores a evaluar.
- **low.value:** valor numérico que marca el límite inferior del subintervalo de interés. Por defecto 0.
- **up.value:** valor numérico que corresponde al límite superior del subintervalo de interés. Por defecto 1.
- **axis:** eje sobre el que se realiza la integración. Puede ser "x" para el dominio de alta especificidad (integración sobre el eje FPR) o "y" para el dominio de alta sensibilidad (integración sobre el eje TPR). Por defecto "x".
- **selection:** vector de caracteres con los nombres de los genes o características de interés. Obligatorio cuando la entrada es un `SummarizedExperiment`.
- **variable:** nombre de la columna de resultado binario en `colData`. Obligatorio cuando la entrada es un `SummarizedExperiment`.
- **output_as_SE:** lógico; si `TRUE` devuelve un `SummarizedExperiment` en lugar de un `tibble`. Por defecto `FALSE`.

La función devuelve por defecto un `tibble` con las columnas `Variable` y `pAUC` para cada predictor, o un `SummarizedExperiment` si se especifica `output_as_SE = TRUE`. El resultado sirve de base para el cálculo de los cuatro índices escalados.

NpAUC: Esta función calcula el índice escalado de área parcial de Jiang et al. (1996) en el dominio de alta sensibilidad. La función acepta los siguientes parámetros:

- **dataset:** contiene la información a partir de la cual se generará la curva ROC. Puede ser un objeto de tipo `data.frame` o `SummarizedExperiment`. En caso de ser un `data.frame`, la primera columna debe ser el Gold Standard binario y las siguientes columnas los predictores a evaluar.
- **low.value:** valor numérico en $[0, 1]$ que marca el límite inferior del subintervalo de sensibilidad (TPR). Por defecto 0.9.
- **up.value:** valor numérico en $[0, 1]$ que corresponde al límite superior del subintervalo de sensibilidad (TPR). Por defecto 1.
- **plot:** lógico; si `TRUE` genera las gráficas de curvas ROC para los predictores analizados. Por defecto `FALSE`.
- **plot_type:** tipo de representación gráfica. Puede ser "combined" (superposición de todas las curvas), "individual" (un panel por predictor) o "both" (ambos). Por defecto "combined".
- **selection:** vector de caracteres con los nombres de los genes o características de interés. Obligatorio cuando la entrada es un `SummarizedExperiment`.
- **variable:** nombre de la columna de resultado binario en `colData`. Obligatorio cuando la entrada es un `SummarizedExperiment`.
- **plots_per_page:** número máximo de paneles individuales por página en el modo "individual". Por defecto 2.
- **output_as_SE:** lógico; si `TRUE` devuelve un `SummarizedExperiment` en lugar de un `tibble`. Por defecto `FALSE`.

La función `NpAUC` llama a la función `pointsCurve` para construir la curva ROC empírica de cada predictor. Una vez obtenida la curva, recorta el subintervalo de sensibilidad de interés, verifica la condición de acotamiento de la RVN y calcula el índice escalado mediante la fórmula de Jiang et al. (1996). La función devuelve por defecto un `tibble` con las columnas `Variable`, `NpAUC` y `pAUC` para cada predictor, o un `SummarizedExperiment` si se especifica `output_as_SE = TRUE`. Cabe destacar que cuando la condición de acotamiento de la RVN no se satisface para un predictor, la función devuelve `NA` para ese caso con un aviso explícito.

FpAUC: Esta función calcula el índice escalado de área parcial de Franco & Vivo (2021) en el dominio de alta sensibilidad. La función acepta los mismos argumentos que NpAUC.

La función FpAUC llama a la función `pointsCurve` para construir la curva ROC empírica de cada predictor. Una vez obtenida la curva, clasifica automáticamente su forma mediante el Algoritmo 1 de Franco & Vivo (2021), determinando el tipo de curva (BpNLR, pProp u other) y aplicando las cotas óptimas correspondientes a cada caso. La función devuelve por defecto un tibble con las columnas `Variable`, `FpAUC` y `pAUC` para cada predictor, o un `SummarizedExperiment` si se especifica `output_as_SE = TRUE`. A diferencia de NpAUC, FpAUC garantiza valores en $[0.5, 1]$ para cualquier forma de curva ROC, por lo que nunca devuelve NA por razones de forma de la curva.

allIndices: Esta función calcula simultáneamente los cuatro índices escalados —MCpAUC, TpAUC, NpAUC y FpAUC— en una sola llamada, aplicando los mismos parámetros de subintervalo a todos ellos (Franco & Vivo, 2021; Jiang et al., 1996; McClish, 1989; Vivo et al., 2018). La función acepta los siguientes argumentos:

- **dataset:** contiene la información a partir de la cual se generará la curva ROC. Puede ser un objeto de tipo `data.frame` o `SummarizedExperiment`. En caso de ser un `data.frame`, la primera columna debe ser el Gold Standard binario y las siguientes columnas los predictores a evaluar.
- **fpr.low:** valor numérico que marca el límite inferior del subintervalo de falsos positivos para el dominio de alta especificidad. Por defecto 0.
- **fpr.up:** valor numérico que corresponde al límite superior del subintervalo de falsos positivos. Por defecto 0.25.
- **tpr.low:** valor numérico que marca el límite inferior del subintervalo de sensibilidad para el dominio de alta sensibilidad. Por defecto 0.9.
- **tpr.up:** valor numérico que corresponde al límite superior del subintervalo de sensibilidad. Por defecto 1.
- **plot:** lógico; si TRUE genera las gráficas de curvas ROC con las regiones de área parcial sombreadas mediante `ggplot2` (Wickham, 2016). Por defecto FALSE.
- **plot_type:** tipo de representación gráfica. Puede ser "combined" (superposición de todas las curvas), "individual" (un panel por predictor) o "both" (ambos). Por defecto "combined".
- **plots_per_page:** número máximo de paneles individuales por página en el modo "individual". Por defecto 2.
- **selection:** vector de caracteres con los nombres de los genes o características de interés. Obligatorio cuando la entrada es un `SummarizedExperiment`.
- **variable:** nombre de la columna de resultado binario en `colData`. Obligatorio cuando la entrada es un `SummarizedExperiment`.

La función devuelve por defecto un tibble con los valores de los cuatro índices y los pAUC de ambos dominios para cada predictor. Esto la convierte en el punto de entrada recomendado para un primer análisis exploratorio completo del conjunto de biomarcadores, ya que permite obtener en una sola llamada una visión global del rendimiento de cada predictor en ambos dominios clínicos.

NpAUCboot: Esta función extiende NpAUC incorporando estimación de la incertidumbre mediante bootstrap no paramétrico (Canty & Ripley, 2025; Davison & Hinkley, 1997). La función acepta los siguientes argumentos:

- **dataset:** objeto de tipo `data.frame` o `SummarizedExperiment` con los datos a analizar. En caso de ser un `data.frame`, la primera columna debe ser el Gold Standard binario y las siguientes los predictores.
- **low.value:** límite inferior del subintervalo de sensibilidad. Por defecto 0.9.
- **up.value:** límite superior del subintervalo de sensibilidad. Por defecto 1.
- **r:** número de réplicas de remuestreo bootstrap. Por defecto 2000.
- **level:** nivel de confianza para el cálculo del intervalo. Por defecto 0.95.
- **type.interval:** tipo de intervalo de confianza a calcular. Puede ser "perc" (percentil), "norm" (normal), "basic", "stud" (studentizado) o "bca" (bias-corrected accelerated). Por defecto "perc".
- **selection:** genes o características de interés, obligatorio cuando la entrada es un `SummarizedExperiment`.
- **variable:** columna de resultado binario en `colData`, obligatorio cuando la entrada es un `SummarizedExperiment`.
- **output_as_SE:** lógico; si TRUE devuelve un `SummarizedExperiment` en lugar de un tibble. Por defecto FALSE.

- **plot:** lógico; si TRUE genera las representaciones gráficas del análisis bootstrap. Por defecto FALSE.
- **plot_type:** tipo de gráfico bootstrap a generar. Puede ser "ci" (intervalos de confianza), "distribution" (distribución bootstrap con nube de puntos) o "both" (ambos). Por defecto "both".
- **parallel:** método de paralelización para el cálculo bootstrap. Puede ser "no", "multicore" o "snow". Por defecto "no".
- **ncpus:** número de núcleos a utilizar en caso de paralelización. Por defecto 1.

La función devuelve por defecto un tibble con las columnas Variable, NpAUC, sesgo, desviación estándar, límite inferior y límite superior del intervalo de confianza. Opcionalmente devuelve un SummarizedExperiment con las mismas métricas si se especifica `output_as_SE = TRUE`. Cuando el índice puntual es NA para un predictor, el bootstrap se omite automáticamente y todas las columnas de salida se completan con NA.

FpAUCboot: Esta función extiende FpAUC de forma análoga a NpAUCboot, incorporando bootstrap no paramétrico para la cuantificación de la incertidumbre del índice de Franco & Vivo (2021). Acepta exactamente los mismos parámetros que NpAUCboot y devuelve las mismas columnas de resumen en formato tibble o SummarizedExperiment. Dado que FpAUC garantiza valores en [0.5, 1] para cualquier forma de curva, FpAUCboot proporciona intervalos de confianza válidos incluso en los casos en que NpAUCboot devuelve NA.

La Tabla 2 recoge la organización del código fuente final en ocho ficheros con responsabilidades bien definidas, que exporta un total de 8 funciones organizadas en dos grupos: las funciones de estimación puntual (`pointsCurve`, `pAUC`, `NpAUC`, `FpAUC` y `allIndices`) y las funciones bootstrap (`NpAUCboot` y `FpAUCboot`). Todas están documentadas con Roxygen2 e incluyen ejemplos ejecutables (Wickham, Danenberg, et al., 2026). El paquete supera R CMD check con 0 errores, 0 advertencias y 1 nota aceptable.

Tabla 2. Organización del código fuente desarrollado.

Fichero	Responsabilidad
01_roc_curve.R	Construcción empírica de la curva ROC (<code>pointsCurve</code>) y preprocesamiento del dataset (<code>prepare_ROC_dataset</code>)
02_integration.R	Integración trapezoidal sobre el eje FPR (<code>pA_FPR</code>) y sobre el eje TPR (<code>pA_TPR</code>)
03_classification.R	Clasificadores de forma de curva: <code>classification_Tp</code> , <code>classification_Fp</code>
04_index_engines.R	Motores de cálculo de los cuatro índices: MCpA, TpA, NpA y FpA.
05_bootstrap_stats.R	Estadísticos bootstrap: <code>fbootM</code> , <code>fbootT</code> , <code>fbootN</code> , <code>fbootF</code>
06_plotting.R	Representación gráfica de curvas ROC con región de área parcial sombreada
07_format_results.R	Formateo de resultados en tibble y cálculo de estadísticos bootstrap (sesgo, SD, IC)
08_exported_functions.R	Las 8 funciones exportadas con documentación Roxygen2 completa

3.2.2 Dependencias

ggplot2 (Wickham, 2016): librería utilizada para la generación de todas las representaciones gráficas del paquete. Permite construir las curvas ROC con la región de área parcial sombreada, las líneas guía en los límites del subintervalo de interés y las etiquetas semánticas del tipo de curva detectado.

boot (Canty & Ripley, 2025): librería que implementa el remuestreo bootstrap no paramétrico sobre el que se basan las funciones `NpAUCboot` y `FpAUCboot`. Proporciona la función `boot::boot()` para la generación de réplicas de remuestreo y `boot::boot.ci()` para el cálculo de los intervalos de confianza por el método percentil.

SummarizedExperiment (Morgan et al., 2026): librería de Bioconductor que define la clase S4 utilizada como formato de entrada y salida nativo de la funcionalidad desarrollada. Permite integrar en un único objeto la matriz de expresión, los metadatos de muestras (`colData`) y los metadatos de características (`rowData`), facilitando la interoperabilidad con otros paquetes del ecosistema Bioconductor (Gentleman et al., 2004).

S4Vectors (Pagès et al., 2026): librería de Bioconductor que proporciona las estructuras de datos DataFrame utilizadas internamente para construir los objetos SummarizedExperiment de salida mediante la función createSE.

tibble (Müller & Wickham, 2026): librería del ecosistema tidyverse utilizada para el formateo de los resultados de salida por defecto de todas las funciones. Proporciona una representación tabular moderna y legible de los índices calculados.

dplyr (Wickham et al., 2026): librería del ecosistema tidyverse utilizada para la manipulación y transformación de los resultados internos durante el proceso de formateo de salida.

knitr (Xie, 2025): librería declarada en Suggests utilizada para la generación de la viñeta de la funcionalidad desarrollada en formato HTML mediante R Markdown.

caret (Kuhn, 2008): librería utilizada para la selección de variables mediante Eliminación Recursiva de Características (*Recursive Feature Elimination*, RFE) aplicada a los conjuntos de datos clínicos de la Parte 3. Permite identificar los genes con mayor capacidad discriminativa mediante validación cruzada con bosques aleatorios.

3.2.3 Conjuntos de datos

Se utilizaron cuatro conjuntos de datos genómicos organizados en dos grupos según su papel en el análisis. El primer grupo comprende los tres conjuntos de datos empleados como punto de control de validación, reproduciendo los resultados de Franco & Vivo (2021):

golubEssets (Golub et al., 1999): este conjunto de datos contiene perfiles de expresión génica de 7.129 genes en 72 pacientes con leucemia, de los cuales 47 padecen leucemia linfoblástica aguda (ALL) y 25 leucemia mieloide aguda (AML), obtenidos mediante microarray Affymetrix Hgu6800. La variable de respuesta es el subtipo de leucemia (ALL vs AML). Este dataset está disponible en Bioconductor mediante el paquete golubEssets y fue empleado por Franco & Vivo (2021) como caso de estudio de referencia.

plsgenomics (Boulesteix, 2005): este conjunto de datos contiene perfiles de expresión génica de 2.000 genes en 62 muestras de tejido colónico, de las cuales 40 son tumorales y 22 son tejido normal. La variable de respuesta es el tipo de tejido (tumoral vs normal). Este dataset está disponible en CRAN mediante el paquete plsgenomics y fue empleado por Franco & Vivo (2021) como caso de estudio de referencia.

orchratio2 (Pepe et al., 2003): este conjunto de datos contiene perfiles de expresión génica de 1.536 genes en 53 muestras de cáncer de ovario, proporcionado por el laboratorio DABS (*Diagnostic and Biomarkers Statistical Center*) del Fred Hutchinson Cancer Center. La variable de respuesta es el tipo tumoral. Este dataset fue empleado por Franco & Vivo (2021) como caso de estudio de referencia.

El segundo grupo comprende el conjunto de datos empleado como aplicación clínica principal de la nueva funcionalidad en el dominio de alta sensibilidad:

breastCancerVDX (Minn et al., 2007; Wang et al., 2005): este conjunto de datos contiene perfiles de expresión génica obtenidos mediante microarray Affymetrix Human U133a de 22.283 genes en 344 pacientes con cáncer de mama con ganglios linfáticos negativos que no habían recibido tratamiento sistémico adyuvante. La variable de respuesta es igualmente la metástasis a distancia (DMFS, *Distant Metastasis-Free Survival*), codificada de forma binaria. Este dataset está disponible en Bioconductor mediante el paquete breastCancerVDX.

3.3 Validación de la implementación

Para verificar la correcta implementación de los índices NpAUC y FpAUC, se replicaron los resultados numéricos publicados en la sección 4.4 de Franco & Vivo (2021). La estrategia de validación consiste en aplicar las funciones NpAUC y FpAUC sobre los tres conjuntos de datos empleados en dicho artículo —Cáncer de Ovario (orchratio2), Leucemia ALL/AML (golubEssets) y Cáncer de Colon (plsgenomics)— utilizando los mismos genes de referencia, el mismo umbral de sensibilidad ($TPR_0 = 0.9$) y el mismo subintervalo de especificidad ($FPR_1 = 0.25$), y comparar los valores obtenidos con los publicados.

Para cada dataset se seleccionan los dos genes de referencia identificados en Franco & Vivo (2021) y se construye un data.frame con la columna de respuesta binaria (Group: 0 = control, 1 = caso) y los genes de interés. A continuación, se aplica la función `allIndices()` con los parámetros `tpr.low = 0.9`, `tpr.up = 1`, `fpr.low = 0` y `fpr.up = 0.25`, obteniendo simultáneamente los cuatro índices escalados y los pAUC de ambos dominios para cada gen.

El criterio de validación es que la diferencia absoluta entre el valor calculado y el valor publicado sea inferior a 1×10^{-5} para cada gen y cada índice. Este umbral es coherente con la precisión numérica de la aritmética en punto flotante de doble precisión empleada en R (R Core Team, 2026a) y garantiza que las diferencias observadas son de naturaleza computacional y no metodológica.

3.4 Análisis de las nuevas bases de datos

Para demostrar la utilidad biológica de la nueva funcionalidad en un contexto clínico real, se aplicaron los índices NpAUC y FpAUC al conjunto de datos de cáncer de mama breastCancerVDX (Minn et al., 2007; Wang et al., 2005), disponible en Bioconductor. La elección de este dataset responde directamente al dominio de alta sensibilidad que motiva este trabajo: en oncología mamaria el principio clínico establecido es no perder ningún caso de metástasis a distancia, lo que corresponde exactamente al escenario TPR_0 alto donde operan NpAUC y FpAUC (Pepe et al., 2001).

Primero se carga el dataset desde Bioconductor y se extrae la matriz de expresión y el vector de respuesta binaria (metástasis a distancia sí/no, variable DMFS) desde el objeto `ExpressionSet`. Las muestras con valor de respuesta no disponible se eliminan del análisis. Después se aplica un filtro de expresión y variabilidad para reducir la dimensionalidad del espacio de genes. Se retienen únicamente los genes con expresión media superior a 5 en escala $\log_2$ y varianza superior a 0.5, eliminando así los genes con niveles de expresión demasiado bajos o sin variabilidad informativa entre muestras (Dudoit et al., 2002).

Tras aplicar los filtros de expresión media y variabilidad, se realiza una exploración de la capacidad discriminativa individual de cada sonda mediante el cálculo del AUC global empleando la función pAUC del paquete ROCpAI con dominio completo (`low.value = 0`, `up.value = 1`). Dado que el AUC depende de la orientación del predictor, se aplica una corrección de orientación tomando $\max(\text{AUC}, 1 - \text{AUC})$ para cada sonda, garantizando que todos los valores reflejan la capacidad discriminativa máxima independientemente del sentido del efecto (Franco & Vivo, 2021).

Para seleccionar los genes de interés, se aplica el método de Eliminación Recursiva de Características con Validación Cruzada (RFE-CV) (Kuhn, 2008) sobre el conjunto completo de sondas preprocesadas, que permite identificar de forma global las sondas con mayor capacidad discriminativa en el dataset obteniendo el conjunto final de genes candidatos sobre los que se realiza el análisis ROC.

Para finalizar, se seleccionan los genes mejor posicionados por el RFE-CV y se realiza una anotación biológica de los mismos. Sobre estos genes candidatos se aplica la función `allIndices()` con los parámetros `tpr.low = 0.9`, `tpr.up = 1`, `fpr.low = 0` y `fpr.up = 0.25`. Para aquellos genes cuyo AUC individual sea inferior a 0.5, se aplica inversión del predictor ($-\text{gen}$) antes del análisis ROC, de forma coherente con la corrección de orientación aplicada en la etapa de filtrado. Finalmente, se cuantifica la incertidumbre de los índices mediante bootstrap no paramétrico con `NpAUCboot` y `FpAUCboot` ($R = 10.000$ réplicas, IC percentil 95 %, $TPR_0 = 0.9$).

3.5 Repositorio en Github

El código fuente completo utilizado para el desarrollo de la nueva funcionalidad, incluyendo todos los pasos del análisis — preprocesamiento, selección de variables, cálculo de índices y validación bootstrap — se encuentra disponible en el repositorio público de GitHub del autor: <https://github.com/achumillas/TFM>. Este repositorio contiene el documento R Markdown principal (P0_ROCpAUC_TFM.Rmd) con el pipeline completo reproducible, así como los scripts auxiliares empleados en cada etapa del análisis. El código del paquete ROCpAI con la nueva funcionalidad implementada está disponible de forma independiente en <https://github.com/achumillas/ROCpAUC>, repositorio que contiene los ocho ficheros fuente descritos en la Tabla 2, la documentación Roxygen2 completa y la viñeta del paquete.

4. Resultados

4.1 Validación de la implementación

Se aplicó la nueva funcionalidad a los tres conjuntos de datos genómicos reales para evaluar la utilidad biológica de los índices y comparar el funcionamiento de NpAUC, FpAUC y sus versiones bootstrap ($R = 10,000$) con $TPR_0 = 0.9$ en todos los casos. Se cargó el dataset completo, se seleccionaron los genes de referencia identificados en Franco & Vivo (2021) y se construyó un data.frame operativo con columna Group (0 = control, 1 = caso) y los genes de interés. Las estimaciones puntuales de NpAUC y FpAUC son deterministas y deben coincidir exactamente con los valores publicados en el artículo de Franco & Vivo (2021). La Tabla 3 recoge la comparación para los seis genes de referencia con $TPR_0 = 0.9$.

Tabla 3. Validación puntual vs Franco & Vivo (2021), Tabla 2 ($TPR_0 = 0.9$). FpAUC: 6/6 diferencias $< 10^{-5}$. NpAUC: 2/2 diferencias $< 10^{-5}$ en genes con índice definido y dataset coincidente.

Dataset	Gen	Tipo	NpAUC ref.	NpAUC calc.	Dif. Np	FpAUC ref.	FpAUC calc.	Dif. Fp
Cancer de Ovario	g1243	BpNLR	0.63768	0.63768	0.00	0.86275	0.86274	0
Cancer de Ovario	g1526	pProp	0.63768	NA	NA	0.85853	0.85853	0
Leucemia	U57721_at	BpNLR	0.63958	0.65958	0.02	0.88571	0.88571	0
Leucemia	X07743_at	BpNLR	0.63958	0.65958	0.02	0.79487	0.79487	0
Cancer de Colon	Hsa.549	pProp	NA	NA	NA	0.73624	0.73624	0
Cancer de Colon	Hsa.40063	BpNLR	0.2841	0.2841	0.00	0.78125	0.78125	0

Para NpAUC, la validación es parcial por dos razones distintas. En primer lugar, los genes g1526 (tipo pProp) y Hsa.549 (tipo pProp) devuelven NA. En segundo lugar, los genes de leucemia U57721_at y X07743_at presentan una discrepancia de ≈ 0.02 entre el NpAUC de referencia del artículo (0.6395745, derivado de pAUC = 0.06395745) y el calculado con la nueva funcionalidad implementada (0.6595745). Para FpAUC, la validación es completa: las 6/6 diferencias absolutas son inferiores a 10^{-5} .

Los resultados bootstrap de FpAUC y NpAUC para los seis genes de referencia de los tres datasets, permitiendo una comparación directa de la estabilidad de ambos índices. Para cada gen se muestran la estimación puntual, el IC al 95 %, si el IC de NpAUC cruza el umbral de 0.5, y la amplitud del IC de FpAUC como medida de precisión (Tabla 4)

Tabla 4 Comparación bootstrap FpAUC y NpAUC ($r = 10,000$ réplicas, IC percentil 95 %) para los genes de referencia de los tres datasets con $TPR_0 = 0.9$. NA indica que NpAUC no está definido y el bootstrap se omite.

Dataset	Gen	FpAUC	IC FpAUC	NpAUC	IC NpAUC	IC Np < 0.5	Anch. Fp
Ovario	g1243	0.863	[0.784, 1.000]	0.638	[0.527, 0.789]	Sí	0.216
Ovario	g1526	0.859	[0.659, 1.000]	NA	—	—	0.341
Leucemia	U57721_at	0.886	[0.820, 1.000]	0.660	[0.514, 0.762]	Sí	0.180
Leucemia	X07743_at	0.795	[0.768, 1.000]	0.660	[0.501, 0.779]	Sí	0.232
Colon	Hsa.549	0.736	[0.608, 1.000]	NA	—	—	0.392
Colon	Hsa.40063	0.781	[0.680, 1.000]	0.284	[0.143, 0.482]	Sí	0.320

Los intervalos de confianza bootstrap obtenidos con la nueva funcionalidad reproducen el comportamiento descrito en el artículo de referencia: FpAUC proporciona IC válidos y superiores a 0.5 para los seis genes analizados, mientras que NpAUC devuelve NA para g1526 y Hsa.549 y un IC íntegramente por debajo del umbral del azar para Hsa.40063, en todos los casos en concordancia con los resultados publicados por Franco & Vivo (2021).

4.2 Análisis de las bases de datos

4.2.1 Metástasis en cáncer de mama (breastCancerVDX)

Tras aplicar el pipeline de preprocesamiento y selección descrito en la Sección 3.4 al dataset breastCancerVDX (344 muestras válidas; 118 con metástasis, 226 sin metástasis; 22.283 genes disponibles), el filtro de expresión media ≥ 5 en escala $\log_2$ y varianza ≥ 0.5 redujo el espacio de genes a 10.324 sondas. Tras aplicar la corrección de orientación mediante max (AUC, $1 - \text{AUC}$), el RFE-CV identificó cinco genes candidatos como los más relevantes, los cuales fueron anotados biológicamente para verificar su función caracterizada en el contexto del cáncer de mama.

EEF1A2 es un oncogén potencial sobreexpresado en dos tercios de los tumores de mama, y esta sobreexpresión se asocia fuertemente con la positividad para el receptor de estrógenos. EEF1A2 desencadena un programa metastásico mediado por ERK más potente en células de cáncer de mama ER negativo que en células ER positivo, modulando el proceso de metástasis de forma subtipo-dependiente. Es el gen con mayor respaldo bibliográfico directo en cáncer de mama del panel. (Tomlinson et al., 2005).

NOL3: La proteína ARC (codificada por NOL3), normalmente limitada a células terminalmente diferenciadas, se induce en cáncer de mama humano y confiere resistencia a quimioterapia y radioterapia. NOL3/ARC actúa como represor de apoptosis en tumores de mama, ovario y colon (Medina-Ramirez et al., 2011).

ZBTB10 es un factor de transcripción supresor tumoral en cáncer de mama y colon reprimiendo la transactivación de la proteína de especificidad (Sp), lo que inhibe el crecimiento tumoral, la quimioresistencia y la metástasis (Jiang et al., 2025)

DDX24 es una ARN helicasas DEAD-box asociadas al cáncer de mama se incluye DDX24, identificada en estudios de reordenamientos genómicos aberrantes en cáncer de mama. DDX24 promueve la migración e invasión celular regulando la ubiquitinación y degradación de RPL5, un supresor tumoral vinculado a p53. La evidencia es en cáncer de pulmón principalmente, con mención directa en mama (Cai et al., 2017; Hu et al., 2022).

GAS2 es una proteína microfilamentosa asociada a la parada del ciclo celular y a la apoptosis dependiente de p53, cuya expresión está específicamente reducida en tumores de mama y próstata respecto al tejido normal (Ma et al., 2025)

La función *allIndices()* se aplicó a los genes candidatos con $\text{FPR}_1 = 0.25$ (alta especificidad) y $\text{TPR}_0 = 0.9$ (alta sensibilidad). La Figura 1 muestra las curvas ROC en el dominio de alta sensibilidad junto con la clasificación automática de cada curva.

Los cinco genes se clasifican como *Improper* (Figura 1) en la banda $\text{TPR} \in [0.9, 1]$, lo que impide que NpAUC proporcione valores válidos, devolviendo NA en todos los casos (Tabla 5). Este resultado, lejos de ser excepcional, ilustra el escenario habitual en datos de expresión génica de alta dimensionalidad donde FpAUC se convierte en el único índice aplicable (Franco & Vivo, 2021).




Figura 1. Curvas ROC de EEF1A2, NOL3, ZBTB10, DDX24 y GAS2 (breastCancerVDX, 344 muestras) con *allIndices()* ($TPR_0 = 0.9$). Los cinco genes se clasifican como *Improper*.

Los valores de FpAUC oscilan entre 0.640 y 0.719, situándose todos por encima del umbral de referencia de 0.5 y confirmando que los cinco genes presentan capacidad discriminatoria real en la región de alta sensibilidad clínicamente relevante para la detección de metástasis a distancia.

ZBTB10 obtiene el valor más alto (FpAUC = 0.770), situándolo como el mejor biomarcador del conjunto en el dominio de alta sensibilidad. DDX24 ocupa la segunda posición (FpAUC = 0.727), seguido de NOL3 (FpAUC = 0.719), GAS2 (FpAUC = 0.701) y EEF1A2 (FpAUC = 0.640). La diferencia entre el mejor y el peor biomarcador es de 0.130 puntos, lo que indica una heterogeneidad moderada en la capacidad discriminatoria de los genes seleccionados en esta región (Tabla 5).

Tabla 5. Estimación puntual de los índices obtenida con *allIndices()* para los genes candidatos del dataset *breastCancerVDX*. $FPR_1 = 0.25$ (MCpAUC, TpAUC) y $TPR_0 = 0.9$ (NpAUC, FpAUC). NA indica que la condición de validez del índice no se satisface para esa curva.

Gen	pAUC_TPR	NpAUC	FpAUC
EEF1A2	0.00818	NA	0.63975
NOL3	0.00679	NA	0.71913
ZBTB10	0.00862	NA	0.77048
DDX24	0.00542	NA	0.72693
GAS2	0.00338	NA	0.70116

El análisis bootstrap ($R = 10.000$ réplicas, IC percentil 95 %, $TPR_0 = 0.9$) confirma los resultados de la estimación puntual. Para NpAUC, el análisis bootstrap se omite automáticamente para los cinco genes al devolver NA la estimación puntual en todos los casos, consecuencia directa de que ninguna curva satisface la condición de acotamiento de la RVN en la banda de alta sensibilidad. Este resultado

muestra la necesidad de FpAUC como alternativa robusta en datos de expresión génica de alta dimensionalidad (Franco & Vivo, 2021).




Figura 2. Análisis bootstrap de FpAUC para los genes candidatos del dataset breastCancerVDX ($R = 10.000$ réplicas, IC percentil 95 %, $TPR_0 = 0.9$). a) Intervalos de confianza FpAUC. b) Distribución bootstrap FpAUC; distribuciones concentradas en [0.65, 0.85].

En cambio, los IC de FpAUC (Figura 2) están completamente por encima de 0.5 para los cinco genes, confirmando que ninguno de los biomarcadores seleccionados presenta inestabilidad bootstrap en la región de alta sensibilidad. ZBTB10 obtiene el IC más elevado [0.641, 0.856] con $SD = 0.056$, consolidando su posición como el mejor biomarcador del conjunto tanto en estimación puntual como en estabilidad bootstrap. DDX24 presenta el segundo IC más alto [0.624, 0.845] con $SD = 0.057$. NOL3, GAS2 y EEF1A2 muestran IC similares entre sí, [0.620, 0.829], [0.606, 0.828] y [0.623, 0.824] respectivamente, con SD en torno a 0.054. Las distribuciones bootstrap muestran que la gran mayoría de las réplicas se concentran en la región [0.65, 0.86] para ZBTB10 y DDX24, y en [0.62, 0.83] para NOL3, GAS2 y EEF1A2, evidenciando la estabilidad estadística de FpAUC en este contexto (Tabla 6).

La distribución bootstrap de FpAUC (Figura 2) muestra una forma aproximadamente simétrica para los cinco genes, con el estimador original (rombo naranja) situado coherentemente dentro de la distribución remuestrada en todos los casos. La amplitud de los intervalos, similar entre genes (rango intercuartílico ≈ 0.10 en todos), refleja una incertidumbre estadística homogénea y coherente con el tamaño muestral disponible (344 muestras).

Tabla 6. Resultados bootstrap de FpAUC para los genes candidatos del dataset breastCancerVDX ($R = 10.000$ réplicas, IC percentil 95 %, $TPR_0 = 0.9$). NpAUC devuelve NA para todos los genes y el bootstrap se omite automáticamente.

Gen	FpAUC	Sesgo	SD	IC 95% lwr	IC 95% upr
EEF1A2	0.6397	0.0803	0.0509	0.6234	0.8235
NOL3	0.7191	0.0047	0.0541	0.6203	0.8293
ZBTB10	0.7705	-0.0213	0.0555	0.6414	0.8557
DDX24	0.7269	0.0118	0.0568	0.6237	0.8449
GAS2	0.7012	0.0129	0.0567	0.6060	0.8276

5. Discusión

5.1 Funcionalidad implementada sobre ROCpAI

El paquete ROCpAI (Garcia et al., 2026) implementa únicamente los índices MCpAUC (McClish, 1989) y TpAUC (Vivo et al., 2018), para la evaluación de biomarcadores en el dominio de alta especificidad (FPR bajo), sin cobertura para los escenarios donde la prioridad es garantizar una sensibilidad mínima (Pepe et al., 2003; Thompson & Zucchini, 1989). La funcionalidad desarrollada en este trabajo se plantea como una herramienta implementable sobre dicho paquete, no disponible en su versión actual, que amplía su ámbito de aplicación en cuatro dimensiones.

En primer lugar, se incorporan los índices NpAUC (Jiang et al., 1996) y FpAUC (Franco & Vivo, 2021) para el dominio de alta sensibilidad, cubriendo así los dos escenarios clínicos fundamentales en diagnóstico oncológico (Dodd & Pepe, 2003). Además de un soporte nativo para objetos *SummarizedExperiment* (Morgan et al., 2026) integra la funcionalidad desarrollada de forma natural en los flujos de trabajo estándar de Bioconductor (Gentleman et al., 2004). También, incorpora un sistema de visualización mejorado que muestra la curva ROC con la región de área parcial sombreada, líneas de referencia en los límites FPR_1 o TPR_0 y una etiqueta automática con el tipo de curva detectado (Franco & Vivo, 2021; Vivo et al., 2018), generando automáticamente las representaciones para los cuatro índices en ambos dominios mediante *allIndices()* con `plot = TRUE` (Ginestet, 2011), facilitando así la comparación visual entre biomarcadores y la comunicación de resultados en publicaciones científicas. Finalmente, la documentación Roxygen2 completa para las 8 funciones exportadas, con ejemplos ejecutables y verificación formal mediante R CMD check (0 errores, 0 advertencias) (R Core Team, 2026b), garantiza la reproducibilidad y la correcta integración del paquete en el ecosistema Bioconductor (Gentleman et al., 2004).

5.2 Validación con los datasets de Franco & Vivo (2021)

La validación de la funcionalidad implementada se realizó reproduciendo los resultados publicados en Franco & Vivo (2021) sobre los tres datasets de referencia: Cáncer de Ovario, Leucemia y Cáncer de Colon. La Tabla 3 y Tabla 4 recogen las comparaciones entre los valores de referencia publicados y los calculados mediante la implementación desarrollada en este trabajo.

Los valores de FpAUC coinciden con los de referencia en todos los casos con una diferencia de 0.00 en cinco de los seis genes analizados, y de 0.00001 en g1243 (0.86275 vs 0.86274), diferencia atribuible exclusivamente al redondeo numérico de la última cifra decimal. Los valores de NpAUC reproducen exactamente los publicados en los casos donde el índice está definido: g1243 (0.63768), Hsa.40063 (0.2841) y los dos genes de Leucemia (0.65958 para ambos), con diferencia 0.00 en todos ellos. Para g1526 y Hsa.549, NpAUC devuelve NA de forma correcta, ya que sus curvas no satisfacen la condición de acotamiento de la razón de verosimilitud negativa parcial en la banda $TPR \in [0.9, 1]$ (Franco & Vivo, 2021).

Ambos genes producen el mismo valor de NpAUC —generando un empate que el índice es incapaz de resolver— mientras que FpAUC devuelve valores diferenciados (0.88571 para U57721_at y 0.79487 para X07743_at), permitiendo establecer una clasificación entre biomarcadores que NpAUC no puede proporcionar.

5.3 Aplicación a datos de expresión génica de alta dimensionalidad: breastCancerVDX

La aplicación de la funcionalidad implementada al dataset *breastCancerVDX* (Minn et al., 2007; Wang et al., 2005) constituye la primera validación en un escenario de expresión génica de alta dimensionalidad real, con 344 muestras y 22.283 sondas disponibles tras el preprocesamiento. El pipeline aplicado —prefiltros de expresión media y varianza y selección mediante RFE con validación cruzada— identificó cinco genes candidatos (EEF1A2, NOL3, ZBTB10, DDX24 y GAS2) como los más discriminatorios para el *outcome* de metástasis a distancia.

Desde el punto de vista biológico, dos de los cinco genes seleccionados presentan evidencia directa y sólida en cáncer de mama y metástasis. *EEF1A2* es un oncogén sobreexpresado en dos tercios de los tumores de mama que activa la migración celular y la remodelación del citoesqueleto de actina a través de la vía Akt, con un papel documentado en la modulación del proceso metastásico de forma subtipo-dependiente (Tomlinson et al., 2005). *NOL3* codifica la proteína ARC, un represor de apoptosis inducido en cáncer de mama primario que confiere resistencia a quimioterapia y radioterapia, dificultando la eliminación de células con potencial metastásico (Medina-Ramírez et al., 2011). Los tres genes restantes presentan una relación más indirecta con el proceso: *ZBTB10* actúa como supresor tumoral reprimiendo la vía Sp en cáncer de mama (Jiang et al., 2025), *DDX24* ha sido identificada en estudios de reordenamientos genómicos en cáncer de mama promoviendo migración e invasión celular (Cai et al., 2017; Hu et al., 2022), y *GAS2* es una proteína microfilamentosa cuya expresión está reducida en tumores de mama respecto al tejido normal, con función reguladora sobre la apoptosis dependiente de p53 (Ma et al., 2025). Que estos tres genes, con evidencia bibliográfica menos consolidada en metástasis de mama, aparezcan seleccionados conjuntamente por el RFE y presenten valores de FpAUC comparables a los de *EEF1A2* y *NOL3* sugiere que podrían constituir candidatos a futuros biomarcadores de metástasis a distancia en cáncer de mama, hipótesis que requeriría validación experimental independiente.

En lo que respecta a los índices de área parcial, los cinco genes clasifican como Improper, lo que impide que NpAUC proporcione valores válidos en ningún caso. Este resultado, coherente con la alta prevalencia de curvas impropias en datos de expresión génica de alta dimensionalidad descrita por Franco & Vivo (2021), pone de manifiesto la necesidad de FpAUC como único índice aplicable en este contexto. Los valores de FpAUC oscilan entre 0.640 y 0.770, situándose todos por encima del umbral de referencia de 0.5 y confirmando capacidad discriminatoria real en el dominio de alta sensibilidad para los cinco biomarcadores. *ZBTB10* destaca sobre el resto con el valor más alto (FpAUC = 0.770), superando en 0.130 puntos al peor biomarcador del conjunto (*EEF1A2*, FpAUC = 0.640), lo que lo sitúa como el mejor candidato del panel en la región clínicamente relevante para la detección de metástasis a distancia pese a no ser uno de los genes con mayor respaldo bibliográfico directo. Este resultado ilustra precisamente una de las propiedades más relevantes de FpAUC: su capacidad para detectar señal discriminatoria en la región de alta sensibilidad de forma independiente al grado de caracterización biológica previa del gen.

El análisis bootstrap ($R = 10.000$ réplicas, IC percentil 95%) confirma la robustez de estos resultados. Los IC de FpAUC están completamente por encima de 0.5 para los cinco genes, con límites inferiores entre 0.606 (*GAS2*) y 0.641 (*ZBTB10*), y *ZBTB10* consolida su posición como mejor biomarcador del conjunto también en términos de estabilidad bootstrap (IC [0.641, 0.856]). La amplitud homogénea de los intervalos ($SD \approx 0.055$ en todos los genes) refleja una incertidumbre estadística coherente con el tamaño muestral disponible y la naturaleza de los datos de expresión génica de alta dimensionalidad.

5.4 Limitaciones

Los resultados de este trabajo están sujetos a una serie de limitaciones que conviene considerar al interpretar las conclusiones y al extrapolar los análisis a otros contextos.

El pipeline de selección de biomarcadores aplicado al dataset *breastCancerVDX* combina múltiples etapas de filtrado y selección — prefiltros de expresión media y varianza y RFE con validación cruzada — sobre un único dataset sin validación externa independiente. Los cinco genes identificados (*EEF1A2*, *NOL3*, *ZBTB10*, *DDX24* y *GAS2*) deben considerarse candidatos exploratorios cuya capacidad discriminatoria real para metástasis a distancia requeriría confirmación en cohortes independientes antes de cualquier aplicación clínica (Dupuy & Simon, 2007; Subramanian & Simon, 2010). La ausencia de un conjunto de test externo impide estimar el grado de sobreajuste introducido por el pipeline de selección, una limitación inherente a los estudios exploratorios de expresión génica de alta dimensionalidad con tamaños muestrales moderados (Ambroise & McLachlan, 2002).

Finalmente, aunque la funcionalidad implementada supera R CMD check sin errores ni advertencias, no incorpora actualmente tests de hipótesis formales para la comparación estadística entre índices de distintos biomarcadores (Chaibub Neto et al., 2024; Pencina et al., 2008). La comparación se realiza exclusivamente mediante la superposición visual de los intervalos de confianza bootstrap (Davison & Hinkley, 1997), lo que puede resultar insuficiente cuando las diferencias entre genes son pequeñas y los tamaños muestrales son reducidos (DeLong et al., 1988).

5.5 Trabajo futuro

Los resultados de este trabajo abren varias líneas de desarrollo que ampliarían la utilidad y el alcance de la funcionalidad desarrollada. El objetivo más inmediato sería la publicación formal de esta funcionalidad como parte del paquete ROCpAI en Bioconductor, lo que requeriría superar el proceso de revisión por pares, actualizar la viñeta y adaptar el código a los estándares de la versión vigente en el momento de la *submission* (Gentleman et al., 2004), dotando así a la comunidad científica de acceso estable a los índices NpAUC y FpAUC dentro del ecosistema estándar de análisis bioinformático.

La extensión más inmediata sería la implementación de tests de hipótesis formales para la comparación de índices pAUC entre biomarcadores (DeLong et al., 1988; Pencina et al., 2008). El estimador de Chaibub-Neto et al. (2024) para el pAUC bidireccional constituye un punto de partida natural, y su integración en el paquete permitiría determinar si las diferencias observadas entre FpAUC de dos genes son estadísticamente significativas, más allá de la superposición de los IC bootstrap (Davison & Hinkley, 1997).

Una segunda línea de interés es la extensión al pAUC bidireccional, que impone restricciones simultáneas tanto en el eje FPR como en el eje TPR (Chaibub Neto et al., 2024; Dodd & Pepe, 2003). Este escenario, más exigente desde el punto de vista clínico, no está cubierto por ninguno de los cuatro índices actuales y requeriría el desarrollo de nuevas fórmulas de escalado y nuevos clasificadores de forma de curva (Franco & Vivo, 2021; Krzanowski & Hand, 2009).

La integración con los flujos de trabajo estándar de Bioconductor para análisis diferencial —DESeq2 (Love et al., 2014) y limma (Ritchie et al., 2015)— constituye otra mejora relevante: actualmente el usuario debe seleccionar manualmente los genes de interés antes de aplicar la funcionalidad desarrollada, mientras que una integración directa permitiría evaluar automáticamente los índices pAUC sobre los genes diferencialmente expresados resultantes de un análisis previo (Gentleman et al., 2004).

Por último, el soporte para clasificadores múltiples y curvas ROC multivariantes ampliaría el ámbito de aplicación del paquete más allá de los biomarcadores univariantes (Krzanowski & Hand, 2009; Pepe et al., 2003), permitiendo evaluar paneles de genes o modelos de predicción combinados mediante los mismos índices de área parcial escalada.

6. Conclusiones

1. Se ha desarrollado una funcionalidad implementable sobre el paquete ROCpAI (Garcia et al., 2026) que incorpora los índices NpAUC (Jiang et al., 1996) y FpAUC (Franco & Vivo, 2021) para el dominio de alta sensibilidad, añadiendo soporte nativo para objetos SummarizedExperiment y mejorando el sistema de visualización. Las 8 funciones exportadas están documentadas con Roxygen2 y superan R CMD check con 0 errores y 0 advertencias.
2. La implementación reproduce con diferencias inferiores a 10^{-5} los valores de FpAUC publicados en Franco & Vivo (2021) para los seis genes de referencia, y devuelve NA con aviso explícito cuando NpAUC no está matemáticamente definido, validando la corrección de la implementación.
3. La aplicación al dataset breastCancerVDX identificó cinco genes candidatos a biomarcadores de metástasis a distancia en cáncer de mama. ZBTB10 destaca como el mejor del panel (FpAUC = 0.770, IC 95%: [0.641, 0.856]), con NpAUC = NA para los cinco genes al clasificarse todas las curvas como impropias.
4. FpAUC supera a NpAUC en dos aspectos críticos: produce valores coherentes en [0.5, 1] para cualquier forma de curva ROC, incluidas las impropias, y discrimina biomarcadores con igual pAUC. El análisis bootstrap confirma esta superioridad: ningún IC de FpAUC cruza el umbral de 0.5 en ninguno de los genes analizados, mientras que el IC de NpAUC puede situarse íntegramente por debajo de dicho umbral.

Referencias

- Ambroise, C., & McLachlan, G. J. (2002). Selection bias in gene extraction on the basis of microarray gene-expression data. *Proceedings of the National Academy of Sciences*, 99(10), 6562-6566. <https://doi.org/10.1073/pnas.102102699>
- Bandos, A. I., Guo, B., & Gur, D. (2017). Estimating the Area Under ROC Curve When the Fitted Binormal Curves Demonstrate Improper Shape. *Academic Radiology*, 24(2), 209-219. <https://doi.org/10.1016/j.acra.2016.09.020>
- Boulesteix, A.-L. (2005). *plsgenomics: PLS Analyses for Genomics* (Versión R package version 1.5-2. Dataset colon cancer. URL: <https://cran.r-project.org/package=plsgenomics>, p. 1.5-3) [Software]. <https://doi.org/10.32614/CRAN.package.plsgenomics>
- Cai, W., Xiong Chen, Z., Rane, G., Satendra Singh, S., Choo, Z., Wang, C., Yuan, Y., Zea Tan, T., Arfuso, F., Yap, C. T., Pongor, L. S., Yang, H., Lee, M. B., Cher Goh, B., Sethi, G., Benoukraf, T., Tergaonkar, V., & Prem Kumar, A. (2017). Wanted DEAD/H or Alive: Helicases Winding Up in Cancers. *JNCI: Journal of the National Cancer Institute*, 109(6), djw278. <https://doi.org/10.1093/jnci/djw278>
- Canty, A., & Ripley, B. D. (2025). *boot: Bootstrap R (S-Plus) Functions* (Versión R package version 1.3-32) [R]. <https://doi.org/10.32614/CRAN.package.boot>
- Chaibub Neto, E., Yadav, V., Sieberts, S. K., & Omberg, L. (2024). A novel estimator for the two-way partial AUC. *BMC Medical Informatics and Decision Making*, 24(1), 57. <https://doi.org/10.1186/s12911-023-02382-2>
- Cleves, M. A. (2002). From the Help Desk: Comparing Areas under Receiver Operating Characteristic Curves from Two or more Probit or Logit Models. *The Stata Journal*, 2(3), 301-313. <https://doi.org/10.1177/1536867X0200200307>
- Davison, A. C., & Hinkley, D. V. (1997). *Bootstrap Methods and their Application*. Cambridge University Press. <https://doi.org/10.1017/CBO9780511802843>
- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the Areas under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach. *Biometrics*, 44(3), 837-845. <https://doi.org/10.2307/2531595>
- Dodd, L. E., & Pepe, M. S. (2003). Partial AUC Estimation and Regression. *Biometrics*, 59(3), 614-623. <https://doi.org/10.1111/1541-0420.00071>
- Dudoit, S., Fridlyand, J., & Speed, T. P. (2002). Comparison of Discrimination Methods for the Classification of Tumors Using Gene Expression Data. *Journal of the American Statistical Association*, 97(457), 77-87. <https://doi.org/10.1198/016214502753479248>
- Dupuy, A., & Simon, R. M. (2007). Critical Review of Published Microarray Studies for Cancer Outcome and Guidelines on Statistical Analysis and Reporting. *JNCI: Journal of the National Cancer Institute*, 99(2), 147-157. <https://doi.org/10.1093/jnci/djk018>
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861-874. <https://doi.org/10.1016/j.patrec.2005.10.010>
- Franco, M., & Vivo, J.-M. (2021). Evaluating the Performances of Biomarkers over a Restricted Domain of High Sensitivity. *Mathematics*, 9(21), 2826. <https://doi.org/10.3390/math9212826>
- Garcia, J.-P., Franco, M., & Vivo, J.-M. (2026). *ROCpAI: Receiver Operating Characteristic Partial Area Indexes for evaluating classifiers* [Software]. <http://bioconductor.org/packages/ROCpAI/>
- Gentleman, R. C., Carey, V. J., Bates, D. M., Bolstad, B., Dettling, M., Dudoit, S., Ellis, B., Gautier, L., Ge, Y., Gentry, J., Hornik, K., Hothorn, T., Huber, W., Iacus, S., Irizarry, R., Leisch, F., Li, C., Maechler, M., Rossini, A. J., ... Zhang, J. (2004). Bioconductor: Open software development for computational biology and bioinformatics. *Genome Biology*, 5(10), R80. <https://doi.org/10.1186/gb-2004-5-10-r80>
- Ginestet, C. (2011). ggplot2: Elegant Graphics for Data Analysis. *Journal of the Royal Statistical Society Series A: Statistics in Society*, 174(1), 245-246. https://doi.org/10.1111/j.1467-985X.2010.00676_9.x
- Golub, T. R., Slonim, D. K., Tamayo, P., Huard, C., Gaasenbeek, M., Mesirov, J. P., Coller, H., Loh, M. L., Downing, J. R., Caligiuri, M. A., Bloomfield, C. D., & Lander, E. S. (1999). Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring. *Science*, 286(5439), 531-537. <https://doi.org/10.1126/science.286.5439.531>
- Hanley, J. A. (1988). The Robustness of the «Binormal» Assumptions Used in Fitting ROC Curves. *Medical Decision Making*, 8(3), 197-203. <https://doi.org/10.1177/0272989X8800800308>
- Hu, X., Li, F., Zhou, Y., Gan, H., Wang, T., Li, L., Long, H., Li, B., & Pang, P. (2022). DDX24 promotes metastasis by regulating RPL5 in non-small cell lung cancer. *Cancer Medicine*, 11(23), 4513-4525. <https://doi.org/10.1002/cam4.4835>
- Jiang, Y., Han, F., Dai, L., Qiu, S., Zhou, Y., Wang, K., & Lin, J. (2025). ZBTB10 as a potential prognosis biomarker and correlates with the tumor immune microenvironment in stomach

- adenocarcinoma. *BMC Gastroenterology*, 25, 435. <https://doi.org/10.1186/s12876-025-04047-y>
- Jiang, Y., Metz, C. E., & Nishikawa, R. M. (1996). A receiver operating characteristic partial area index for highly sensitive diagnostic tests. *Radiology*, 201(3), 745-750. <https://doi.org/10.1148/radiology.201.3.8939225>
- Krzanowski, W. J., & Hand, D. J. (2009). *ROC curves for continuous data*. CRC Press.
- Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. *Journal of Statistical Software*, 28(5), 1-26. <https://doi.org/10.18637/jss.v028.i05>
- Love, M. I., Huber, W., & Anders, S. (2014). Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, 15(12), 550. <https://doi.org/10.1186/s13059-014-0550-8>
- Ma, W., Lin, J., Ma, R., Bai, Y., Wu, D., Zhang, X., Zhou, H., Zhao, Y., & Zhang, L. (2025). Insights into Structure and Function of Growth Arrest Specific 2 (GAS2). *Journal of Cancer*, 16(1), 146-156. <https://doi.org/10.7150/jca.102893>
- McClish, D. K. (1989). Analyzing a Portion of the ROC Curve. *Medical Decision Making*, 9(3), 190-195. <https://doi.org/10.1177/0272989X8900900307>
- Medina-Ramirez, C. M., Goswami, S., Smirnova, T., Bamira, D., Benson, B., Ferrick, N., Segall, J., Pollard, J. W., & Kitsis, R. N. (2011). Apoptosis Inhibitor ARC Promotes Breast Tumorigenesis, Metastasis, and Chemoresistance. *Cancer Research*, 71(24), 7705-7715. <https://doi.org/10.1158/0008-5472.CAN-11-2192>
- Metz, C. E. (1978). Basic principles of ROC analysis. *Seminars in Nuclear Medicine*, 8(4), 283-298. [https://doi.org/10.1016/S0001-2998\(78\)80014-2](https://doi.org/10.1016/S0001-2998(78)80014-2)
- Minn, A. J., Gupta, G. P., Padua, D., Bos, P., Nguyen, D. X., Nuyten, D., Kreike, B., Zhang, Y., Wang, Y., Ishwaran, H., Foekens, J. A., van de Vijver, M., & Massagué, J. (2007). Lung metastasis genes couple breast tumor size and metastatic spread. *Proceedings of the National Academy of Sciences*, 104(16), 6740-6745. <https://doi.org/10.1073/pnas.0701138104>
- Morgan, M., Obenchain, V., Hester, J., & Pagès, H. (2026). *SummarizedExperiment: A container (S4 class) for matrix-like assays* [R package version 1.42.0]. <https://doi.org/10.18129/B9.bioc.SummarizedExperiment>.
- Morgan, M., & Shepherd, L. (2026). *ExperimentHub: Client to access ExperimentHub resources*. <https://github.com/Bioconductor/ExperimentHub>
- Müller, K., & Wickham, H. (2026). *tibble: Simple Data Frames* (Versión R package version 3.3.1, p. 3.3.1) [Software]. <https://doi.org/10.32614/CRAN.package.tibble>
- Pagès, H., Lawrence, M., & Aboyoun, P. (2026). *S4Vectors: Foundation of vector-like and list-like containers in Bioconductor* (Versión R package version 0.50.1) [Software]. Bioconductor. <https://doi.org/10.18129/B9.bioc.S4Vectors>
- Pankla, R., Buddhisa, S., Berry, M., Blankenship, D. M., Bancroft, G. J., Banchereau, J., Lertmemongkolkhai, G., & Chaussabel, D. (2009). Genomic transcriptional profiling identifies a candidate blood biomarker signature for the diagnosis of septicemic melioidosis. *Genome Biology*, 10(11), R127. <https://doi.org/10.1186/gb-2009-10-11-r127>
- Pencina, M. J., D'Agostino Sr, R. B., D'Agostino Jr, R. B., & Vasan, R. S. (2008). Evaluating the added predictive ability of a new marker: From area under the ROC curve to reclassification and beyond. *Statistics in Medicine*, 27(2), 157-172. <https://doi.org/10.1002/sim.2929>
- Pepe, M. S. (2003). *The Statistical Evaluation of Medical Tests for Classification and Prediction*. Oxford University Press. <https://doi.org/10.1093/oso/9780198509844.001.0001>
- Pepe, M. S., Etzioni, R., Feng, Z., Potter, J. D., Thompson, M. L., Thornquist, M., Winget, M., & Yasui, Y. (2001). Phases of Biomarker Development for Early Detection of Cancer. *JNCI: Journal of the National Cancer Institute*, 93(14), 1054-1061. <https://doi.org/10.1093/jnci/93.14.1054>
- Pepe, M. S., Longton, G., Anderson, G. L., & Schummer, M. (2003). Selecting differentially expressed genes from microarray experiments. *Biometrics*, 59(1), 133-142. <https://doi.org/10.1111/1541-0420.00016>
- R Core Team. (2026a). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://doi.org/10.32614/R.manuals>
- R Core Team. (2026b). *R: The R Project for Statistical Computing* [Software]. <https://www.r-project.org/>
- Ramos, M., Schiffer, L., Re, A., Azhar, R., Basunia, A., Cabrera, C. R., Chan, T., Chapman, P., Davis, S., Gomez-Cabrero, D., Culhane, A. C., Haibe-Kains, B., Hansen, K., Kodali, H., Louis, M. S., Mer, A. S., Reister, M., Morgan, M., Carey, V. J., & Waldron, L. (2017). Software For The Integration Of Multi-Omics Experiments In Bioconductor. *Cancer Research*, 77(21), e39-42. <https://doi.org/10.1158/0008-5472.CAN-17-0344>
- Ritchie, M. E., Phipson, B., Wu, D., Hu, Y., Law, C. W., Shi, W., & Smyth, G. K. (2015). Limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Research*, 43(7), e47. <https://doi.org/10.1093/nar/gkv007>

- Sing, T., Sander, O., Beerenwinkel, N., & Lengauer, T. (2005). ROCr: Visualizing classifier performance in R. *Bioinformatics*, 21(20), 3940-3941. <https://doi.org/10.1093/bioinformatics/bti623>
- Singhania, A., Verma, R., Graham, C. M., Lee, J., Tran, T., Richardson, M., Lecine, P., Leissner, P., Berry, M. P. R., Wilkinson, R. J., Kaiser, K., Rodrigue, M., Woltmann, G., Haldar, P., & O'Garra, A. (2018). A modular transcriptional signature identifies phenotypic heterogeneity of human tuberculosis infection. *Nature Communications*, 9, 2308. <https://doi.org/10.1038/s41467-018-04579-w>
- Subramanian, J., & Simon, R. (2010). Gene Expression-Based Prognostic Signatures in Lung Cancer: Ready for Clinical Use? *JNCI: Journal of the National Cancer Institute*, 102(7), 464-474. <https://doi.org/10.1093/jnci/djq025>
- Thompson, M. L., & Zucchini, W. (1989). On the statistical analysis of ROC curves. *Statistics in Medicine*, 8(10), 1277-1290. <https://doi.org/10.1002/sim.4780081011>
- Tomlinson, V. A., Newbery, H. J., Wray, N. R., Jackson, J., Larionov, A., Miller, W. R., Dixon, J. M., & Abbott, C. M. (2005). Translation elongation factor eEF1A2 is a potential oncoprotein that is overexpressed in two-thirds of breast tumours. *BMC Cancer*, 5(1), 113. <https://doi.org/10.1186/1471-2407-5-113>
- van 't Veer, L. J., Dai, H., van de Vijver, M. J., He, Y. D., Hart, A. A. M., Mao, M., Peterse, H. L., van der Kooy, K., Marton, M. J., Witteveen, A. T., Schreiber, G. J., Kerkhoven, R. M., Roberts, C., Linsley, P. S., Bernards, R., & Friend, S. H. (2002). Gene expression profiling predicts clinical outcome of breast cancer. *Nature*, 415(6871), 530-536. <https://doi.org/10.1038/415530a>
- Vivo, J.-M., Franco, M., & Vicari, D. (2018). Rethinking an ROC partial area index for evaluating the classification performance at a high specificity range. *Advances in Data Analysis and Classification*, 12(3), 683-704. <https://doi.org/10.1007/s11634-017-0295-9>
- Wang, Y., Klijn, J. G., Zhang, Y., Sieuwerts, A. M., Look, M. P., Yang, F., Talantov, D., Timmermans, M., Gelder, M. E. M., Yu, J., Jatkoe, T., Berns, E. M., Atkins, D., & Foekens, J. A. (2005). Gene-expression profiles to predict distant metastasis of lymph-node-negative primary breast cancer. *The Lancet*, 365(9460), 671-679. [https://doi.org/10.1016/S0140-6736\(05\)17947-1](https://doi.org/10.1016/S0140-6736(05)17947-1)
- Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis* (2nd ed. 2016). Springer International Publishing : Imprint: Springer. <https://doi.org/10.1007/978-3-319-24277-4>
- Wickham, H., Danenberg, P., Csárdi, G., & Eugster, M. (2026). *roxygen2: In-Line Documentation for R* (Versión R package version 8.0.0.) [Software]. <https://doi.org/10.32614/CRAN.package.roxygen2>
- Wickham, H., François, R., Henry, L., Müller, K., & Vaughan, D. (2026). *dplyr: A Grammar of Data Manipulation* (p. 1.2.1) [Software]. <https://doi.org/10.32614/CRAN.package.dplyr>
- Xie, Y. (2025). *knitr: A General-Purpose Package for Dynamic Report Generation in R* (Versión R package version 1.51, p. 1.51) [Software]. <https://doi.org/10.32614/CRAN.package.knitr>

Apéndice. Objetivos de Desarrollo Sostenible

De acuerdo con la recomendación de la Guía Docente del Máster en Bioinformática de la Universidad de Murcia, se indican a continuación los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 a los que contribuye este trabajo:

ODS 3 — Salud y Bienestar. La funcionalidad desarrollada proporciona herramientas estadísticas para la evaluación rigurosa de biomarcadores diagnósticos en enfermedades como leucemia, cáncer de colon, cáncer de ovario y cáncer de mama. La introducción de FpAUC como alternativa robusta a NpAUC en presencia de curvas ROC impropias contribuye directamente al desarrollo de herramientas para la medicina de precisión y el diagnóstico molecular, facilitando la identificación de los biomarcadores con mayor capacidad discriminatoria en condiciones clínicas de alta sensibilidad.

ODS 9 — Industria, Innovación e Infraestructura. La funcionalidad desarrollada se plantea para su distribución como software libre a través de Bioconductor, una infraestructura de referencia en bioinformática de código abierto. La documentación Roxygen2 completa, los ejemplos ejecutables y la verificación formal mediante R CMD check promueven la innovación metodológica accesible, transparente y reproducible para la comunidad científica global. La arquitectura modular del código en ficheros con responsabilidades bien definidas facilita además su mantenimiento y extensión futura por parte de otros desarrolladores.